

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aplicación de Máquinas de Soporte Vectorial en la Clasificación de Datos Complejos	2
1.	Aplicación de Máquinas de Soporte Vectorial en la Clasificación de Datos Complejos	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	4
1.2.1.	Principio de Separación Óptima	4
1.2.2.	Funciones Kernel	4
1.2.3.	Parámetros de Regularización	4
1.3.	Metodología y Análisis de la Literatura	5
1.4.	Aplicaciones en Datos Complejos	5
1.4.1.	Clasificación de Datos Genómicos	5
1.4.2.	Clasificación de Grafos	5
1.4.3.	Procesamiento de Señales Biomédicas	6
1.4.4.	Máquinas de Soporte Vectorial Cuánticas	6
1.5.	Optimización de Hiperparámetros	6
1.5.1.	Inferencia Bayesiana	6
1.5.2.	Particle Swarm Optimization (PSO)	7
1.5.3.	Artificial Bee Colony (ABC)	7
1.6.	Discusión	7
1.7.	Conclusiones	7

Parte I

Introducción y Fundamentos

Parte II

Aplicación de Máquinas de Soporte Vectorial en la Clasificación de Datos Complejos

Capítulo 1

Aplicación de Máquinas de Soporte Vectorial en la Clasificación de Datos Complejos

Autor: Richard Ariel Chamba Santin

Técnica asignada: Máquinas de Soporte Vectorial (SVM)

1.1. Introducción

En el contexto moderno de los Sistemas Inteligentes y el Aprendizaje Automático, las Máquinas de Soporte Vectorial (Support Vector Machines, SVM) se han consolidado como uno de los modelos supervisados más eficientes para resolver problemas de clasificación y reconocimiento de patrones [1]. Su capacidad para trabajar con espacios de alta dimensionalidad, muestras reducidas y estructuras de datos complejas ha permitido su adopción en áreas como bioinformática, visión computacional, procesamiento de señales biomédicas y análisis financiero.

La clasificación de datos complejos representa actualmente uno de los mayores desafíos computacionales debido a características como:

- Alta dimensionalidad de atributos.
- Presencia de ruido y redundancia.
- Datos no linealmente separables.
- Representaciones no vectoriales, como grafos o señales dinámicas.
- Volúmenes masivos de información.

En este escenario, las SVM destacan debido a su fundamento matemático basado en optimización convexa y teoría estadística del aprendizaje. Además, mediante el uso de funciones kernel, estas máquinas pueden transformar espacios de entrada complejos en representaciones donde la separación lineal resulta viable [6].

El presente capítulo analiza formalmente cómo las Máquinas de Soporte Vectorial son aplicadas en la clasificación de datos complejos, estudiando sus fundamentos teóricos, variantes modernas, métodos de optimización y aplicaciones científicas contemporáneas.

1.2. Fundamentos Teóricos

1.2.1. Principio de Separación Óptima

El objetivo principal de una SVM consiste en encontrar un hiperplano óptimo que maximice la distancia entre dos clases de datos [1]. Dado un conjunto de entrenamiento:

$$\{(x_i, y_i)\}_{i=1}^n \quad (1.1)$$

donde x_i representa el vector de características y $y_i \in \{-1, 1\}$ corresponde a la clase asociada, la SVM busca minimizar:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (1.2)$$

sujeito a:

$$y_i(w^T x_i + b) \geq 1 \quad (1.3)$$

La maximización del margen permite mejorar la capacidad de generalización del modelo, reduciendo el riesgo de sobreajuste sobre los datos de entrenamiento.

1.2.2. Funciones Kernel

Muchos problemas reales presentan distribuciones no lineales imposibles de separar mediante hiperplanos tradicionales. Para resolver este inconveniente, las SVM utilizan funciones kernel que permiten proyectar los datos hacia espacios de mayor dimensionalidad [3].

Entre los kernels más utilizados se encuentran:

- **Kernel Lineal**

$$K(x, y) = x^T y \quad (1.4)$$

- **Kernel Polinomial**

$$K(x, y) = (x^T y + 1)^d \quad (1.5)$$

- **Kernel Gaussiano RBF**

$$K(x, y) = e^{-\frac{\|x-y\|^2}{2\sigma^2}} \quad (1.6)$$

- **Kernel Sigmoide**

$$K(x, y) = \tanh(\gamma x^T y + c) \quad (1.7)$$

El kernel RBF es uno de los más utilizados debido a su capacidad para modelar fronteras altamente no lineales.

1.2.3. Parámetros de Regularización

El desempeño de una SVM depende críticamente de la selección de hiperparámetros, especialmente:

- C : controla el equilibrio entre maximización del margen y errores de clasificación.
- γ : regula la influencia de cada muestra en kernels RBF.

La selección incorrecta de estos parámetros puede generar subajuste o sobreajuste del modelo [6].

1.3. Metodología y Análisis de la Literatura

Para el desarrollo del presente capítulo se realizó una revisión bibliográfica de artículos científicos indexados en IEEE Xplore y bases de datos académicas de alto impacto. Los trabajos seleccionados fueron organizados considerando:

- Tipo de dato complejo analizado.
- Variante de SVM utilizada.
- Técnica de optimización aplicada.
- Resultados de precisión y rendimiento computacional.

La Tabla 1.1 resume las principales aplicaciones identificadas en la literatura científica reciente.

Tabla 1.1: Aplicaciones contemporáneas de SVM en datos complejos.

Área	Modelo SVM	Objetivo
Bioinformática	SVM-mRMRe	Clasificación de cáncer mediante genes
Procesamiento biomédico	Twin SVM	Clasificación de señales cardíacas
Análisis financiero	QSVM	Predicción de riesgo financiero
Clasificación de grafos	SVM + LSH	Reducción de complejidad computacional
Detección de fatiga	PSO-SVM	Optimización automática de parámetros

1.4. Aplicaciones en Datos Complejos

1.4.1. Clasificación de Datos Genómicos

En bioinformática, los microarreglos genéticos presentan miles de características y un número reducido de muestras. Esta relación genera problemas de dimensionalidad extrema y sobreajuste [2].

Para resolver este problema, se desarrolló el modelo híbrido SVM-mRMRe, el cual combina:

- Ranking estadístico de características.
- Selección de genes relevantes.
- Eliminación de redundancia biológica.

Los resultados muestran mejoras significativas en precisión diagnóstica para distintos tipos de cáncer.

1.4.2. Clasificación de Grafos

La clasificación de grafos constituye un problema computacional complejo debido a la dificultad de representar estructuras topológicas mediante vectores tradicionales. Para abordar esta limitación, investigaciones recientes integran SVM con técnicas de *Locality-Sensitive Hashing* (LSH) [1].

Este enfoque reduce considerablemente:

- El consumo de memoria.
- El costo computacional cuadrático.
- Los tiempos de entrenamiento.

1.4.3. Procesamiento de Señales Biomédicas

En sistemas médicos inteligentes, las SVM son ampliamente utilizadas para analizar señales EEG y fonocardiogramas. La variante Twin Support Vector Machine (TWSVM) construye dos hiperplanos no paralelos, permitiendo acelerar el proceso de clasificación [4].

Esta arquitectura logra:

- Mayor velocidad de entrenamiento.
- Menor complejidad computacional.
- Alta precisión diagnóstica.

En aplicaciones clínicas en tiempo real, estas características resultan fundamentales para sistemas de monitoreo automático.

1.4.4. Máquinas de Soporte Vectorial Cuánticas

La Computación Cuántica ha impulsado el desarrollo de Quantum Support Vector Machines (QSVM), capaces de trabajar sobre espacios de Hilbert de dimensiones extremadamente elevadas [3].

Los modelos QSVM utilizan algoritmos variacionales cuánticos para:

- Reducir tiempos de procesamiento.
- Modelar relaciones complejas no lineales.
- Mejorar tareas predictivas de alta complejidad.

A pesar de sus ventajas, actualmente presentan limitaciones relacionadas con:

- Ruido cuántico.
- Estabilidad del hardware.
- Escalabilidad práctica.

1.5. Optimización de Hiperparámetros

La eficiencia de las SVM depende fuertemente de la correcta configuración de hiperparámetros. Por esta razón, múltiples investigaciones proponen métodos automáticos de optimización [8].

Entre las técnicas más utilizadas destacan:

1.5.1. Inferencia Bayesiana

La inferencia bayesiana permite estimar parámetros óptimos mediante distribuciones probabilísticas y algoritmos MCMC [6]. Este enfoque automatiza la búsqueda de configuraciones eficientes sin necesidad de exploración manual exhaustiva.

1.5.2. Particle Swarm Optimization (PSO)

El algoritmo PSO simula el comportamiento colectivo de partículas para encontrar soluciones óptimas en espacios de búsqueda complejos. Su integración con SVM ha demostrado mejoras importantes en sistemas de detección de fatiga y reconocimiento de patrones [8].

1.5.3. Artificial Bee Colony (ABC)

Los algoritmos ABC modelan el comportamiento de colonias de abejas para optimizar funciones objetivo. Estas técnicas son utilizadas para:

- Ajuste automático de kernels.
- Selección de características.
- Minimización del error de clasificación.

1.6. Discusión

Las Máquinas de Soporte Vectorial continúan siendo una de las técnicas más robustas dentro del aprendizaje supervisado debido a:

- Su sólida fundamentación matemática.
- Alta capacidad de generalización.
- Eficiencia en espacios de alta dimensionalidad.
- Adaptabilidad mediante kernels especializados.

Sin embargo, los desafíos actuales incluyen:

- Escalabilidad en Big Data.
- Alto costo computacional para entrenamiento masivo.
- Sensibilidad a la selección de hiperparámetros.
- Dificultad de interpretación en modelos complejos.

La integración con técnicas híbridas, metaheurísticas y computación cuántica representa una línea prometedora de investigación futura.

1.7. Conclusiones

Las Máquinas de Soporte Vectorial constituyen una herramienta fundamental para la clasificación de datos complejos en sistemas inteligentes modernos. Gracias al uso de kernels, métodos de optimización y arquitecturas híbridas, las SVM han logrado resolver problemas relacionados con bioinformática, procesamiento biomédico, clasificación estructural y análisis financiero.

La literatura científica reciente demuestra que variantes como TWSVM, QSVM y SVM-Lattice permiten mejorar significativamente la precisión y eficiencia computacional frente a enfoques tradicionales. No obstante, persisten retos asociados con la escalabilidad y la complejidad computacional en escenarios de Big Data.

Finalmente, las SVM continúan evolucionando como una técnica central dentro del aprendizaje automático, especialmente cuando se combinan con algoritmos de optimización y paradigmas emergentes como la computación cuántica.

Referencias

- [1] M. D. Gonzalez-Lima, C. C. Ludeña, and G. G. Otazo-Sanchez, “A Graph Classification Method Based on Support Vector Machines and Locality-Sensitive Hashing,” *IEEE Access*, vol. 12, pp. 15791–15799, 2024.
- [2] P. El Kafrawy, H. Fathi, M. Qaraad, A. K. Kelany, and X. Chen, “An Efficient SVM-Based Feature Selection Model for Cancer Classification Using High-Dimensional Microarray Data,” *IEEE Access*, vol. 9, pp. 155353–155369, 2021.
- [3] M. C. Hidalgo, “Comparative Analysis of a Quantum SVM With an Optimized Kernel Versus Classical SVMs,” *IEEE Access*, vol. 13, pp. 82378–82387, 2025.
- [4] J. Li, L. Ke, Q. Du, X. Ding, X. Chen, and D. Wang, “Heart Sound Signal Classification Algorithm: A Combination of Wavelet Scattering Transform and Twin Support Vector Machine,” *IEEE Access*, vol. 7, pp. 179339–179348, 2019.
- [5] H. Yang, C. Qu, J. Cai, S. Zhang, and X. Zhao, “SVM-Lattice: A Recognition and Evaluation Frame for Double-Peaked Profiles,” *IEEE Access*, vol. 8, pp. 80978–80996, 2020.
- [6] J. Jang, U. Jang, and M. Jong, “Selecting Hyperparameters of Nonlinear Support Vector Machine Using Bayesian Inference,” in *Proc. Int. Conf. Mathematics, Intelligent Computing and Machine Learning (MICML)*, 2023, pp. 17–23.
- [7] X. Huang, G. Zhang, and Z. Huo, “Research on Anomaly Detection and Fault Prediction of Flight Data based on Support Vector Machine,” in *Proc. 9th Int. Conf. Cyber Security and Information Engineering (ICCSIE)*, 2024, pp. 269–276.
- [8] C. Tian, L. Zhou, and H. Zhang, “Equipment Test Personnel Fatigue Detection Based on Particle Swarm Optimization and Support Vector Machine,” in *Proc. 2024 8th Int. Conf. Electronic Information Technology and Computer Engineering (EITCE)*, 2024, pp. 1196–1200.
- [9] K. Panchal, K. Khaitan, Kiruthika M, and A. S. Oliver, “Optimization of Support Vector Machine using Firework Algorithm for Breast Cancer Classification,” *IEEE Access*, vol. 12, pp. 1–7, 2024.
- [10] M. P. Chanu, D. Pei, P. Olikkal, R. K. Vinjamuri, and N. M. Kakoty, “Electroencephalogram based Control of Prosthetic Hand using Optimizable Support Vector Machine,” in *Proc. Advances in Robotics (AIR)*, 2023, pp. 1–6.

Referencias