

Aplicación de Máquinas de Soporte Vectorial (SVM) en la Clasificación de Datos Complejos: Metodologías, Desafíos y Tendencias Emergentes

Quick Reference
Key Findings Table

Tema Principal	Hallazgos Clave	Citaciones
Tipos de datos complejos	SVM es eficaz en datos desbalanceados, de alta dimensionalidad y no lineales; destaca en bioinformática, medicina y texto	1234567
Técnicas avanzadas para datos desbalanceados	Algoritmos evolutivos (SEOA), SMOTE-ENN, SVMSMOTE, GANs y métodos híbridos mejoran el rendimiento de SVM	89101112
Reducción de dimensionalidad	SVM+PCA y métodos discriminantes mejoran precisión y eficiencia en bioinformática; KPCA y LLE superan a PCA en ciertos contextos	13141516
Funciones kernel y aprendizaje profundo	Kernels híbridos, kernels para secuencias biológicas, deep kernel learning y automatización de features potencian SVM	1718192021
Comparativa con otros clasificadores	SVM supera a redes neuronales profundas en datos pequeños/alta dimensionalidad; kernel trick aporta robustez	22232425
Escalabilidad y eficiencia	Algoritmos paralelos/distribuidos, implementaciones en GPU/FPGA, y métodos incrementales permiten SVM en big data	262728293031
Métodos híbridos y evolutivos	Integración con algoritmos evolutivos/metaheurísticos mejora selección de características y ajuste de hiperparámetros	3233343536
Brechas y tendencias	Escalabilidad a billones de instancias, tuning automático en entornos débilmente supervisados, extensión a dominios complejos	3738394041

Direct Answer

Support Vector Machines se aplican a la clasificación de datos complejos mediante el uso de funciones kernel para mapear datos a espacios de alta dimensionalidad (abordando no linealidad), integración de métodos avanzados de remuestreo e híbridos para tratar desbalances, y acoplamiento con técnicas de reducción de

dimensionalidad como PCA para manejar alta dimensionalidad. Además, innovaciones metodológicas como deep kernel learning y marcos híbridos SVM-evolutivos emergen para mejorar el ajuste de parámetros y acelerar el entrenamiento en datos a gran escala [2](#) [3](#) [20](#) [22](#) [27](#) [42](#).

Study Scope

- **Periodo:** Última década, con énfasis en avances recientes (2018-2024).
- **Disciplinas:** Bioinformática, medicina, procesamiento de texto, visión por computador, ingeniería, big data.
- **Métodos:** Meta-análisis de estudios empíricos, revisiones sistemáticas, experimentos comparativos, desarrollos algorítmicos y aplicaciones en dominios reales.

Assumptions & Limitations

- **Supuestos:** Se asume acceso a recursos computacionales para métodos avanzados (GPU/FPGA), disponibilidad de datos etiquetados y posibilidad de aplicar técnicas de reducción de dimensionalidad.
- **Limitaciones:** Persisten retos en escalabilidad para billones de instancias, tuning automático en entornos débilmente supervisados, y extensión a dominios con ruido o etiquetas incompletas [37](#) [39](#) [40](#).

Suggested Further Research

- Desarrollo de SVM escalables para big data (billones de instancias).
- Automatización total del ajuste de hiperparámetros en entornos con supervisión débil.
- Extensión de SVM a dominios complejos (hipercomplejos, datos con ruido/etiquetas incompletas).
- Integración de deep kernel learning con aceleradores hardware (FPGA/GPU) para procesamiento en tiempo real [37](#) [38](#) [39](#) [40](#) [41](#).

1. Introducción

La clasificación de datos complejos es un desafío central en inteligencia artificial, especialmente en dominios donde los datos presentan alta dimensionalidad, desbalance de clases, estructuras no lineales o ruido. Las Máquinas de Soporte Vectorial (SVM) han emergido como una de las técnicas más robustas y versátiles para abordar estos retos, gracias a su sólida fundamentación teórica y capacidad de adaptación mediante funciones kernel y estrategias híbridas [1](#) [43](#). Su relevancia se extiende a campos como la bioinformática, medicina, procesamiento de texto y big data, donde la precisión y la capacidad de generalización son críticas.

Contexto y Motivación

El auge de datos complejos en aplicaciones modernas —desde la predicción de enfermedades hasta la detección de fraudes y el análisis de sentimientos— ha impulsado la búsqueda de clasificadores capaces de manejar alta dimensionalidad, desbalance y no linealidad. SVM destaca por su capacidad de maximizar el margen entre clases y su flexibilidad para incorporar kernels y técnicas de ingeniería de características, lo que la convierte en una herramienta clave en la clasificación moderna [1](#) [43](#).

2. Tipos de Datos Complejos y Desafíos en la Clasificación con SVM

Clasificación de Datos Desbalanceados

El desbalance de clases es común en aplicaciones biomédicas, detección de fraudes y monitoreo ambiental. SVM, aunque robusta, tiende a sesgarse hacia la clase mayoritaria. Para contrarrestar esto, se han desarrollado técnicas avanzadas:

- **Algoritmos evolutivos (SEOA):** Utilizan la información del margen de SVM para generar muestras sintéticas cerca de la frontera de decisión, superando métodos tradicionales como SMOTE [8](#).
- **SMOTE-ENN y variantes híbridas:** Combinan sobre-muestreo sintético con limpieza de ruido, mejorando la precisión y el F1-score en dominios como salud y medio ambiente [9](#) [44](#) [45](#).
- **GANs para generación de datos sintéticos:** Mejoran la detección de clases minoritarias en salud, superando a SMOTE en métricas ROC AUC [11](#).
- **Granular SVM y métodos de submuestreo:** Balancean la distribución minimizando la pérdida de información [46](#).
- **Ensamblados SVM-resampling:** Combinan SVM con técnicas de remuestreo y k-NN, logrando mayor precisión que SVM sola [47](#) [48](#).

Síntesis: La integración de SVM con métodos evolutivos y de remuestreo híbrido es esencial para abordar el desbalance, logrando mejoras significativas en precisión y sensibilidad [8](#) [9](#) [12](#).

Clasificación de Datos de Alta Dimensionalidad

En bioinformática, texto y visión por computador, los datos suelen tener miles de variables y pocos ejemplos. SVM, combinada con reducción de dimensionalidad, es especialmente eficaz:

- **SVM + PCA:** Reduce redundancia y mejora eficiencia computacional, con incrementos de precisión de hasta 10 puntos porcentuales en diagnóstico biomédico [13](#) [14](#) [16](#).
- **Análisis discriminante (QFDA):** Preserva mejor la información discriminante que PCA en tareas multiclase [15](#).
- **Kernel PCA y LLE:** Superan a PCA en tareas no lineales y series temporales [49](#) [50](#).
- **Privacidad diferencial:** Métodos de reducción de dimensionalidad permiten aprendizaje privado sin sacrificar precisión [51](#) [52](#).

Síntesis: La combinación de SVM con reducción de dimensionalidad (PCA, QFDA, KPCA) es una estrategia robusta para datos de alta dimensionalidad, manteniendo alta precisión y eficiencia [13](#) [14](#) [15](#) [16](#).

Clasificación de Datos No Lineales

Muchos problemas reales presentan relaciones no lineales entre variables. SVM aborda este reto mediante el uso de funciones kernel:

- **Kernel trick:** Permite mapear datos a espacios de alta dimensionalidad donde son linealmente separables [2](#) [42](#) [53](#) [54](#).
- **Selección de kernel:** RBF y kernels híbridos suelen superar a kernels lineales/polinomiales en tareas complejas [18](#) [19](#).
- **Kernels especializados:** String kernels y graph kernels extienden SVM a secuencias biológicas y datos estructurados [55](#).

Síntesis: El diseño y selección de kernels es crucial para la clasificación de datos no lineales, permitiendo a SVM adaptarse a estructuras complejas y mejorar la generalización [18](#) [19](#) [42](#).

Aplicaciones en Dominios Específicos

- **Medicina y bioinformática:** SVM es estándar en clasificación de cáncer, predicción de enfermedades y análisis de expresión génica, donde el desbalance y la alta dimensionalidad son comunes [4](#) [6](#) [7](#).
- **Procesamiento de texto:** SVM, combinada con técnicas de remuestreo, mejora la detección de spam y análisis de sentimientos en datos dispersos [5](#).
- **Visión por computador:** SVM con kernels avanzados y reducción de dimensionalidad logra alta precisión en reconocimiento facial y de emociones [56](#) [57](#).

Síntesis: SVM, adaptada con kernels y técnicas de ingeniería de características, es ampliamente utilizada en dominios donde la complejidad de los datos desafía a otros clasificadores [4](#) [5](#) [6](#) [7](#).

3. Ingeniería de Características y Funciones Kernel en SVM

Diseño y Selección de Funciones Kernel

- **Kernels híbridos y optimizados:** Combinan RBF, polinomial y kernels neuronales, optimizados mediante algoritmos genéticos, logrando mayor precisión y estabilidad en datos clínicos y biológicos [18](#) [58](#) [59](#).
- **Deep kernel learning:** Integra redes neuronales profundas como mapeos kernel, permitiendo aprendizaje jerárquico de características y mejorando la clasificación en datos no lineales [20](#) [21](#).
- **Kernels para secuencias biológicas:** String kernels y kernels histogramados (Hist2Vec) superan a RBF en clasificación de ADN/proteínas [19](#) [55](#).
- **Kernels universales y mixtos:** Combinan propiedades locales y globales, mejorando la generalización [60](#).

Síntesis: La innovación en kernels —desde híbridos hasta deep kernel learning— amplía la capacidad de SVM para capturar relaciones complejas y mejorar la precisión en dominios especializados [18](#) [19](#) [20](#).

Ingeniería y Selección de Características

- **Automatización inspirada en kernel trick:** Genera nuevas características que linealizan relaciones no lineales, mejorando la precisión con kernels simples, aunque puede degradar el rendimiento con kernels

complejos [61](#).

- **Selección de características + optimización de kernel:** Elimina variables irrelevantes y ajusta parámetros kernel, incrementando precisión y AUC en datos médicos [62](#).
- **Reducción de dimensionalidad:** PCA, ICA y RFE son esenciales para acelerar y mejorar la clasificación en SVM [63](#) [64](#).

Síntesis: La ingeniería de características, combinada con la optimización de kernels, es fundamental para potenciar el rendimiento de SVM en datos complejos [61](#) [62](#).

Integración de Aprendizaje Profundo y SVM

- **Deep kernel learning:** Permite que SVM aprenda representaciones jerárquicas mediante redes profundas, mejorando la clasificación en datos no lineales y complejos [20](#) [21](#).
- **Modelos híbridos (CNN+SVM):** El entrenamiento end-to-end permite que las capas de extracción de características se adapten específicamente al clasificador SVM, superando enfoques separados [65](#).
- **Escalabilidad:** Deep kernel learning, combinado con métodos de optimización escalables, permite aplicar SVM a grandes volúmenes de datos [66](#).

Síntesis: La integración de aprendizaje profundo y SVM representa una tendencia emergente que combina la abstracción jerárquica de características con la robustez teórica de SVM [20](#) [21](#) [65](#).

4. Comparativa de SVM con Otros Clasificadores en Datos Complejos

Comparación General de Desempeño

- **SVM vs. clasificadores clásicos:** SVM iguala o supera a regresión logística, árboles de decisión y redes neuronales en datos complejos, gracias a su capacidad de generalización y manejo de alta dimensionalidad [43](#) [67](#) [68](#) [69](#) [70](#) [71](#).
- **SVM vs. deep learning:** SVM es superior en conjuntos de datos pequeños y de alta dimensionalidad, donde deep learning tiende a sobreajustar o requiere grandes volúmenes de datos [22](#) [23](#).
- **Ensamblados y variantes:** Métodos híbridos (SVM+boosting, SVM+GA) pueden superar a SVM estándar y otros clasificadores en tareas específicas [72](#).

Síntesis: SVM mantiene ventajas competitivas en escenarios donde otros clasificadores fallan, especialmente en datos pequeños, ruidosos o de alta dimensionalidad [22](#) [43](#) [68](#) [71](#).

Ventajas de SVM en Datos Pequeños y de Alta Dimensionalidad

- **Teoría del margen:** SVM maximiza el margen entre clases, lo que garantiza buena generalización incluso con pocos datos [22](#) [23](#).

- **Kernel trick:** Permite manejar no linealidad sin requerir grandes volúmenes de datos, a diferencia de deep learning [22](#) [23](#) [38](#).
- **Eficiencia computacional:** SVM es eficiente en memoria y robusta a outliers, ideal cuando el número de variables supera el de muestras [73](#) [74](#).

Síntesis: SVM es preferida en dominios con datos escasos y alta dimensionalidad, donde deep learning no es viable [22](#) [23](#) [73](#).

Impacto del Kernel Trick en Robustez y Generalización

- **Transformación implícita:** El kernel trick permite separar datos no lineales en espacios de alta dimensionalidad, mejorando la robustez ante distribuciones irregulares [24](#) [75](#) [76](#).
- **Fundamento teórico:** SVM ofrece garantías de generalización basadas en la teoría del VC, superando a redes neuronales en escenarios con ruido o datos desconocidos [23](#) [25](#).
- **Optimización de kernels:** Algoritmos genéticos y nuevos diseños kernel potencian la robustez y adaptabilidad de SVM [24](#) [42](#) [77](#).

Síntesis: El kernel trick es el pilar de la robustez y capacidad de generalización de SVM frente a datos complejos y distribuciones desconocidas [23](#) [24](#) [25](#).

Optimización y Eficiencia en SVM Multiclase

- **Sequential Minimum Optimization (SMO):** Reduce el tiempo de entrenamiento y mejora la precisión en escenarios multiclase y con solapamiento de muestras [78](#) [79](#).
- **Modelos jerárquicos y clustering:** Dividen el problema en subespacios, acelerando el entrenamiento y mejorando la precisión [79](#) [80](#).
- **Metaheurísticas:** Algoritmos como ant colony y sparrow search optimizan parámetros y selección de características, mejorando eficiencia y robustez [81](#) [82](#).

Síntesis: Las técnicas de optimización y modelos jerárquicos permiten aplicar SVM eficientemente en problemas multiclase y con solapamiento, manteniendo alta precisión [78](#) [79](#) [83](#).

5. Tendencias Emergentes y Desarrollos Recientes en SVM

Escalabilidad y SVM para Big Data

- **Algoritmos paralelos/distribuidos:** Permiten clasificar billones de instancias en minutos usando clusters estándar [26](#) [27](#).
- **Implementaciones en GPU/FPGA:** Aceleran el entrenamiento y clasificación, logrando speedups de hasta 24x (GPU) y 2-3 órdenes de magnitud (FPGA) respecto a CPU [28](#) [29](#) [30](#) [31](#).

- **Métodos incrementales y aproximados:** Reducen la complejidad de memoria y tiempo, facilitando el uso de SVM en big data [84](#) [85](#).

Síntesis: La escalabilidad de SVM se potencia mediante paralelización, hardware especializado y algoritmos incrementales, habilitando su uso en big data [26](#) [27](#) [29](#) [31](#).

Métodos Híbridos y Algoritmos Evolutivos

- **Integración con algoritmos evolutivos:** GAs, ACO, DE y otros optimizan simultáneamente selección de características y ajuste de hiperparámetros, mejorando precisión y robustez [32](#) [33](#) [34](#) [35](#) [36](#).
- **Híbridos con boosting y clustering:** AdaBoost+SVM y métodos fuzzy-clustering mejoran la adaptabilidad y reconocimiento en entornos ruidosos [86](#) [87](#).
- **Optimización multicriterio:** Permite balancear precisión, tiempo de entrenamiento y complejidad del modelo [88](#).

Síntesis: Los métodos híbridos y evolutivos son clave para adaptar SVM a datos complejos, optimizando automáticamente parámetros y selección de variables [32](#) [34](#) [35](#).

Nuevos Desafíos y Direcciones Futuras

- **Escalabilidad extrema:** Persisten retos en el manejo eficiente de billones de instancias y datos de muy alta dimensionalidad [37](#) [40](#).
- **Aprendizaje débilmente supervisado:** Falta automatización en tuning de parámetros y adaptación a etiquetas incompletas o ambiguas [39](#) [40](#).
- **Extensión a dominios hipercomplejos:** Aplicaciones en procesamiento cuántico, señales complejas y datos espaciotemporales requieren nuevas variantes de SVM [38](#) [89](#).
- **Integración con big data y hardware:** Se requieren nuevos métodos de preparación de datos y entrenamiento para aprovechar tecnologías big data y hardware especializado [40](#) [41](#) [90](#).

Síntesis: Las tendencias emergentes apuntan a la escalabilidad, automatización y extensión de SVM a dominios cada vez más complejos, integrando tecnologías de hardware y big data [37](#) [38](#) [39](#) [40](#) [41](#).

6. Conclusiones

Síntesis de Resultados y Perspectivas

Las Máquinas de Soporte Vectorial (SVM) han demostrado ser una herramienta poderosa y adaptable para la clasificación de datos complejos, gracias a su sólida base teórica, flexibilidad mediante funciones kernel y capacidad de integración con técnicas avanzadas de ingeniería de características y métodos híbridos. SVM sobresale en escenarios de alta dimensionalidad, desbalance y no linealidad, superando a modelos profundos en conjuntos de datos pequeños y ruidosos. Las innovaciones recientes en kernels, aprendizaje profundo y escalabilidad mediante hardware especializado y algoritmos paralelos amplían aún más su aplicabilidad.

Sin embargo, persisten desafíos en la escalabilidad extrema, automatización del ajuste de parámetros y adaptación a entornos débilmente supervisados. El futuro de SVM se orienta hacia la integración con tecnologías de big data, deep kernel learning y hardware acelerado, así como la extensión a dominios hipercomplejos y de alto volumen.

Oportunidades de investigación futura incluyen:

- SVM escalables para big data y entornos distribuidos.
- Automatización total del tuning de hiperparámetros.
- Extensión a dominios con etiquetas incompletas, ruido y estructuras complejas.
- Integración de deep kernel learning con aceleradores hardware para aplicaciones en tiempo real 37 38 39 40 41.

En resumen, SVM sigue siendo una técnica central y en evolución para la clasificación de datos complejos, combinando fundamentos teóricos sólidos con adaptabilidad práctica y potencial de innovación tecnológica.

References

1. The application of problems concerning the imbalanced data classification by means of support vector machines Qing, C. Proceedings - 2011 4th International Symposium on Knowledge Acquisition and Modeling, KAM 2011, 2011 <https://www.scopus.com/pages/publications/84857321415?origin=scopusAI>
2. Support Vector Machine (SVM) pattern recognition to AVO classification Li, J., Castagna, J. Geophysical Research Letters, 2004 <https://www.scopus.com/pages/publications/2442543099?origin=scopusAI>
3. Complex Layers of Formal Neurons Bobrowski, L. Communications in Computer and Information Science, 2022 <https://www.scopus.com/pages/publications/85133029687?origin=scopusAI>
4. Adaptive Multiclassification With Lung Cancer Types Using High-Dimensional Discriminant Analysis and Machine Learning Methods Araveeporn, A. International Journal of Mathematics and Mathematical Sciences, 2025 <https://www.scopus.com/pages/publications/105019398784?origin=scopusAI>
5. A Computational Model for Imbalanced Data Challenges of Movie Review Using Adaptive Synthetic Sampling Rana, S., Kanji, R., Jain, S. Lecture Notes in Networks and Systems, 2025 <https://www.scopus.com/pages/publications/105015599089?origin=scopusAI>
6. Machine Learning Algorithms for Health Care Data Analytics Handling Imbalanced Datasets Sajana, T., Rama Rao, K.V.S.N. Handbook of Artificial Intelligence, 2023 <https://www.scopus.com/pages/publications/85207589913?origin=scopusAI>
7. Imbalanced Data Classification using Optimized Support Vector Machine for IoMT Application Pattanayak, B.K., Mohanty, M.N., Satpathy, S., Arjun Das, J.B. 2023 2nd International Conference on Ambient Intelligence in Health Care, ICAIHC 2023, 2023 <https://www.scopus.com/pages/publications/85186759171?origin=scopusAI>
8. Enhancing Imbalanced Classification with Support Vector Machines via Evolutionary Oversampling Algorithms Wang, H., Chen, Y., Zhang, C., (...), Zhang, Q. 2024 IEEE Congress on Evolutionary Computation, CEC 2024 - Proceedings, 2024 <https://www.scopus.com/pages/publications/85201736179?origin=scopusAI>
9. SMOTE-ENN Resampling to Optimize Diabetes Prediction in Imbalanced Data Setiawan, A.E., Rustad, S., Syukur, A., (...), Setiawan, A.W. Ingenierie des Systemes d'Information, 2025

<https://www.scopus.com/pages/publications/105009932678?origin=scopusAI>

10. Optimized Resampling Techniques for Crop Recommendation Systems in Mizoram Agriculture Thihlum, Z., Kumar, V.D.A., Khan, A.K., (...), Roy, R. 2025 IEEE Guwahati Subsection Conference, GCON 2025, 2025 <https://www.scopus.com/pages/publications/105018743930?origin=scopusAI>

11. Synthetic Boosted Resampling Using Deep Generative Adversarial Networks: A Novel Approach to Improve Cancer Prediction from Imbalanced Datasets Gurcan, F., Soylu, A. Cancers, 2024 <https://www.scopus.com/pages/publications/85212128155?origin=scopusAI>

12. Performance of Sampling Methods on Imbalanced Data: Comparative Analysis Butt, A.H., Khan, Z., Khan, A., (...), Kamalov, F. Advances in Science and Engineering Technology International Conferences, ASET, 2024 <https://www.scopus.com/pages/publications/85210241743?origin=scopusAI>

13. Face recognition using principal component analysis and multi-class support vector machine Chawla, K., Bansal, V., Arya, K.V., Shukla, A. Proceedings of the 2010 International Conference on Image Processing, Computer Vision, and Pattern Recognition, IPCV 2010, 2010 <https://www.scopus.com/pages/publications/84864922787?origin=scopusAI>

14. Fault diagnosis for refrigeration systems based on principal component analysis and support vector machine Han, H., Gu, B., Ren, N. Shanghai Jiaotong Daxue Xuebao/Journal of Shanghai Jiaotong University, 2011 <https://www.scopus.com/pages/publications/81355133067?origin=scopusAI>

15. Hyperspectral image classification based on quadratic Fisher's discriminant analysis and multi-class support vector machine Das, R., Dash, R., Majhi, B. IETE Journal of Research, 2014 <https://www.scopus.com/pages/publications/84987971709?origin=scopusAI>

16. Multiclass classification of leukemia cancer data using Fuzzy Support Vector Machine (FSVM) with feature selection using Principal Component Analysis (PCA) Fauzi, I.R., Rustam, Z., Wibowo, A. Journal of Physics: Conference Series, 2021 <https://www.scopus.com/pages/publications/85100762829?origin=scopusAI>

17. Bridging deep and multiple kernel learning: A review Wang, T., Zhang, L., Hu, W. Information Fusion, 2021 <https://www.scopus.com/pages/publications/85092446869?origin=scopusAI>

18. An improved support vector machine for disease diagnosis Tania, F.A., Chandra Shill, P. 2019 22nd International Conference on Computer and Information Technology, ICCIT 2019, 2019 <https://www.scopus.com/pages/publications/85082996916?origin=scopusAI>

19. Hist2Vec: Kernel-Based Embeddings for Biological Sequence Classification Ali, S., Mansoor, H., Chourasia, P., Patterson, M. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), 2023 <https://www.scopus.com/pages/publications/85174311442?origin=scopusAI>

20. Deep neural mapping support vector machines Li, Y., Zhang, T. Neural Networks, 2017 <https://www.scopus.com/pages/publications/85021171148?origin=scopusAI>

21. Deep Kernel machines: a survey Nikhitha, N.K., Afzal, A.L., Asharaf, S. Pattern Analysis and Applications, 2021 <https://www.scopus.com/pages/publications/85096052039?origin=scopusAI>

22. Effect of different kernels on the performance of an SVM based classification Kancherla, D., Bodapati, J.D., Veeranjanyulu, N. International Journal of Recent Technology and Engineering, 2019 <https://www.scopus.com/pages/publications/85072905375?origin=scopusAI>

23. Support Vector Machines Angulo, C., Gonzalez-Abril, L. Encyclopedia of Artificial Intelligence: Volume I-III, 2008 <https://www.scopus.com/pages/publications/105013736827?origin=scopusAI>

24. Optimizing Support Vector Machine Parameters with Genetic Algorithm for Credit Risk Assessment Manurung, J., Mawengkang, H., Zamzami, E. Journal of Physics: Conference Series, 2017 <https://www.scopus.com/pages/publications/85039416583?origin=scopusAI>

25. Exploring Kernel Machines and Support Vector Machines: Principles, Techniques, and Future Directions Du, K.-L., Jiang, B., Lu, J., (...), Swamy, M.N.S. Mathematics, 2024
<https://www.scopus.com/pages/publications/85213385508?origin=scopusAI>
26. Mining very large datasets with support vector machine algorithms Poulet, F., Do, T.-N. ICEIS 2003 - Proceedings of the 5th International Conference on Enterprise Information Systems, 2003
<https://www.scopus.com/pages/publications/84910068253?origin=scopusAI>
27. PSVM: Parallel Support Vector Machines with incomplete cholesky factorization Chang, E.Y., Bai, H., Zhu, K., (...), Qiu, Z. Scaling up Machine Learning: Parallel and Distributed Approaches, 2011
<https://www.scopus.com/pages/publications/84923505588?origin=scopusAI>
28. Recipe for Fast Large-Scale SVM Training: Polishing, Parallelism, and More RAM! Glasmachers, T. Communications in Computer and Information Science, 2023
<https://www.scopus.com/pages/publications/85172143779?origin=scopusAI>
29. Support Vector Machine reconfigurable hardware implementation on FPGA Yacoub, M.H., Ismail, S.M., Said, L.A., (...), Radwan, A.G. Franklin Open, 2024 <https://www.scopus.com/pages/publications/85213315867?origin=scopusAI>
30. A Parallel Digital VLSI Architecture for Integrated Support Vector Machine Training and Classification Wang, Q., Li, P., Kim, Y. IEEE Transactions on Very Large Scale Integration (VLSI) Systems, 2015
<https://www.scopus.com/pages/publications/85028228408?origin=scopusAI>
31. Embedded Low-Power Processor for Personalized Stress Detection Attaran, N., Puranik, A., Brooks, J., Mohsenin, T. IEEE Transactions on Circuits and Systems II: Express Briefs, 2018
<https://www.scopus.com/pages/publications/85041418794?origin=scopusAI>
32. Feature selection and classification via a GA-SVM hybrid Teoh, E.-J., Xiang, C. Proceedings of the 2008 International Conference on Genetic and Evolutionary Methods, GEM 2008, 2008
<https://www.scopus.com/pages/publications/62949157435?origin=scopusAI>
33. Intelligent classification algorithms in enhancing the performance of support vector machine Alwan, H.B., Ku-Mahamud, K.R. Journal of Theoretical and Applied Information Technology, 2019
<https://www.scopus.com/pages/publications/85061383824?origin=scopusAI>
34. Enhanced SVM optimization for diabetes prediction using particle swarm and differential evolution techniques Krishnaraj, S., Sarathambekai, S. Synergizing Data Envelopment Analysis and Machine Learning for Performance Optimization in Healthcare, 2025 <https://www.scopus.com/pages/publications/105010508122?origin=scopusAI>
35. Evolutionarily-tuned support vector machines Dudzik, W., Kawulok, M., Nalepa, J. GECCO 2019 Companion - Proceedings of the 2019 Genetic and Evolutionary Computation Conference Companion, 2019
<https://www.scopus.com/pages/publications/85070570453?origin=scopusAI>
36. A hybrid evolutionary algorithm for attribute selection in data mining Tan, K.C., Teoh, E.J., Yu, Q., Goh, K.C. Expert Systems with Applications, 2009 <https://www.scopus.com/pages/publications/60249094445?origin=scopusAI>
37. Support Vector Machines: Theory, Algorithms, and Applications Jabardi, M. Infocommunications Journal, 2025 <https://www.scopus.com/pages/publications/105002429565?origin=scopusAI>
38. Support vector machine, an important supervised learning category Mathur, P. Artificial Intelligence for Computational Fluid Dynamics, 2026 <https://www.scopus.com/pages/publications/105032949238?origin=scopusAI>
39. Survey on Support Vector Machine Algorithms in Weakly Supervised Scenarios Ding, S.-F., Sun, Y.-T., Liang, Z.-Z., (...), Xu, X. Jisuanji Xuebao/Chinese Journal of Computers, 2024
<https://www.scopus.com/pages/publications/85193220456?origin=scopusAI>

40. Selecting training sets for support vector machines: a review Nalepa, J., Kawulok, M. Artificial Intelligence Review, 2019 <https://www.scopus.com/pages/publications/85040018154?origin=scopusAI>
41. Support vector machine and classification, kernel trick for separating of data points Negi, H.S., Dimri, S.C., Kumar, B., Ram, M. Mathematics in Engineering, Science and Aerospace, 2024 <https://www.scopus.com/pages/publications/85196097910?origin=scopusAI>
42. Improving Support Vector Machine Performance with Advanced Kernel Methods Mittal, M., Al-Jawahry, H.M., Varshney, N., (...), Reddy, R.A. Proceedings of International Conference on Contemporary Computing and Informatics, IC3I 2024, 2024 <https://www.scopus.com/pages/publications/85217412916?origin=scopusAI>
43. The support vector machine under test Meyer, D., Leisch, F., Hornik, K. Neurocomputing, 2003 <https://www.scopus.com/pages/publications/0242288813?origin=scopusAI>
44. A Comparative Study of SMOTE-Based Oversampling Methods for KNN and SVM on Imbalanced Datasets Kinata, M., Nababan, A.A., Tavary, G., (...), Wong, M. 2025 IEEE International Conference on Artificial Intelligence and Mechatronics Systems, AIMS 2025, 2025 <https://www.scopus.com/pages/publications/105025428044?origin=scopusAI>
45. A refined SMOTE-ENN optimization method based on machine learning for heart rate variability data classification Zhang, B., Liang, M., Zhou, Y., (...), Qiao, X. Frontiers in Digital Health, 2026 <https://www.scopus.com/pages/publications/105031089760?origin=scopusAI>
46. SVMs modeling for highly imbalanced classification Tang, Y., Zhang, Y.-Q., Chawla, N.V. IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics, 2009 <https://www.scopus.com/pages/publications/61549114384?origin=scopusAI>
47. A Survey on Solution of Imbalanced Data Classification Problem Using SMOTE and Extreme Learning Machine Goyal, A., Rathore, L., Kumar, S. Lecture Notes in Networks and Systems, 2021 <https://www.scopus.com/pages/publications/85112006004?origin=scopusAI>
48. Handling imbalanced dataset using SVM and k-NN approach Wah, Y.B., Rahman, H.A.A., He, H., Bulgiba, A. AIP Conference Proceedings, 2016 <https://www.scopus.com/pages/publications/84984550446?origin=scopusAI>
49. A comparison of PCA, KPCA and ICA for dimensionality reduction in support vector machine Cao, L.J., Chua, K.S., Chong, W.K., (...), Gu, Q.M. Neurocomputing, 2003 <https://www.scopus.com/pages/publications/0242288799?origin=scopusAI>
50. Clustering and Analysis of Dongguan Red Cultural Heritage Site Data Based on Support Vector Machine (SVM) and Locally Linear Embedding (LLE) Pan, K., Zhou, H., Wu, M. Proceedings of the 2025 2nd International Conference on Computer and Multimedia Technology, ICCMT 2025, 2025 <https://www.scopus.com/pages/publications/105020791932?origin=scopusAI>
51. Strict Differentially Private Support Vector Machines with Dimensionality Reduction Wang, T., Liu, S., Liang, J., (...), Song, J. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), 2024 <https://www.scopus.com/pages/publications/85185706242?origin=scopusAI>
52. Differential Privacy Principal Component Analysis for Support Vector Machines Huang, Y., Yang, G., Xu, Y., Zhou, H. Security and Communication Networks, 2021 <https://www.scopus.com/pages/publications/85112436257?origin=scopusAI>
53. String kernels construction and fusion: a survey with bioinformatics application Qi, R., Guo, F., Zou, Q. Frontiers of Computer Science, 2022 <https://www.scopus.com/pages/publications/85123569408?origin=scopusAI>
54. Novel kernels and kernel PCA for pattern recognition Isaacs, J.C., Foo, S.Y., Meyer-Baese, A. Proceedings of the 2007 IEEE International Symposium on Computational Intelligence in Robotics and Automation, CIRA

2007, 2007 <https://www.scopus.com/pages/publications/34948879165?origin=scopusAI>

55. Using length-weighted once kernel to detect anomalous process Mu, S., Tian, S., Yin, C. Proceedings - Third International Conference on Natural Computation, ICNC 2007, 2007
<https://www.scopus.com/pages/publications/38049088975?origin=scopusAI>

56. Face recognition using kernel UDP Yang, W., Sun, C., Yang, J., (...), Ricanek, K. Neural Processing Letters, 2011 <https://www.scopus.com/pages/publications/80053570718?origin=scopusAI>

57. Efficient application of Gabor filters with nonlinear support vector machines Srivastava, A., Mohapatra, P., Mandal, A.S. Proceedings: Turing 100 - International Conference on Computing Sciences, ICCS 2012, 2012
<https://www.scopus.com/pages/publications/84872536897?origin=scopusAI>

58. Optimizing weighted kernel function for support vector machine by genetic algorithm Nguyen, H.-N., Ohn, S.-Y., Chae, S.-H., (...), Lee, I. Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics), 2006
<https://www.scopus.com/pages/publications/33845924204?origin=scopusAI>

59. A hybrid kernel support vector machine for predicting protein structure Khan, I., Abdul Fattah, H.M., Shill, P.C. 2021 International Conference on Automation, Control and Mechatronics for Industry 4.0, ACMI 2021, 2021 <https://www.scopus.com/pages/publications/85115665246?origin=scopusAI>

60. A local-global mixed kernel with reproducing property Xu, L., Niu, X., Xie, J., (...), Luo, B. Neurocomputing, 2015 <https://www.scopus.com/pages/publications/84937817716?origin=scopusAI>

61. Automated Feature Engineering using Kernel Functions Mahajan, P. 2020 International Conference on Artificial Intelligence and Signal Processing, AISP 2020, 2020
<https://www.scopus.com/pages/publications/85084678063?origin=scopusAI>

62. An integrated approach of feature selection and parameter optimisation of kernel to enhance the performance of support vector machine Sarojini, B. International Journal of Communication Networks and Distributed Systems, 2015 <https://www.scopus.com/pages/publications/84945195355?origin=scopusAI>

63. Feature Reduction for Support Vector Machines Cheng, S., Shih, F.Y. Encyclopedia of Data Warehousing and Mining: Second Edition, 2008 <https://www.scopus.com/pages/publications/105011907541?origin=scopusAI>

64. An empirical comparison study on kernel based support vector machine for classification of gene expression data set Das, S.R., Das, K., Mishra, D., (...), Mishra, S. Procedia Engineering, 2012
<https://www.scopus.com/pages/publications/84872818287?origin=scopusAI>

65. Kernel Support Vector Machines and Convolutional Neural Networks Jiang, S., Hartley, R., Fernando, B. 2018 International Conference on Digital Image Computing: Techniques and Applications, DICTA 2018, 2018
<https://www.scopus.com/pages/publications/85062240046?origin=scopusAI>

66. Deep kernel learning in core vector machines Afzal, A.L., Asharaf, S. Pattern Analysis and Applications, 2018 <https://www.scopus.com/pages/publications/85012231732?origin=scopusAI>

67. Comparative study on classification performance between support vector machine and logistic regression Musa, A.B. International Journal of Machine Learning and Cybernetics, 2013
<https://www.scopus.com/pages/publications/84872352584?origin=scopusAI>

68. A comparison of machine learning algorithms for classification of tropical ecosystems observed by multiple sensors at multiple scales Pouteaua, R., Collinb, A., Stolla, B. 34th International Symposium on Remote Sensing of Environment - The GEOSS Era: Towards Operational Environmental Monitoring, 2011
<https://www.scopus.com/pages/publications/84879779336?origin=scopusAI>

69. A comparative study and performance analysis of classification techniques: Support vector machine, neural networks and decision trees Raychaudhuri, K., Kumar, M., Bhanu, S. Communications in Computer and

Information Science, 2017 <https://www.scopus.com/pages/publications/85028328269?origin=scopusAI>

70. Benchmarking the performance of support vector machines in classifying web pages Wong, W.-P., Chan, K.-X., Soon, L.-K. Communications in Computer and Information Science, 2012
<https://www.scopus.com/pages/publications/84865603259?origin=scopusAI>

71. The classification performance using logistic regression and support vector machine (SVM) Widodo, A., Handoyo, S. Journal of Theoretical and Applied Information Technology, 2017
<https://www.scopus.com/pages/publications/85031750419?origin=scopusAI>

72. A COMPARATIVE STUDY ON PERFORMANCE OF BASIC AND ENSEMBLE CLASSIFIERS WITH VARIOUS DATASETS Gunakala, A., Hussain Shahid, A. Applied Computer Science, 2023
<https://www.scopus.com/pages/publications/85159154475?origin=scopusAI>

73. Support Vector Machine El Morr, C., Jammal, M., Ali-Hassan, H., El-Hallak, W. International Series in Operations Research and Management Science, 2022
<https://www.scopus.com/pages/publications/85143498883?origin=scopusAI>

74. Mammalian eye gene expression using support vector regression to evaluate a strategy for detecting human eye disease Roozbeh, M., Maanavi, M. Iranian Journal of Health Sciences, 2022
<https://www.scopus.com/pages/publications/105010694272?origin=scopusAI>

75. Kernel-based SVM Murty, M.N., Raghava, R. SpringerBriefs in Computer Science, 2016
<https://www.scopus.com/pages/publications/85029627612?origin=scopusAI>

76. Performance Analysis of Heart Disease Prediction using Kernels in Support Vector Machine Model Anggreainy, M.S. ICSINTESA 2024 - 2024 4th International Conference of Science and Information Technology in Smart Administration: The Collaboration of Smart Technology and Good Governance for Sustainable Development Goals, 2024 <https://www.scopus.com/pages/publications/85211601985?origin=scopusAI>

77. CROification: Accurate Kernel Classification with the Efficiency of Sparse Linear SVM Kafai, M., Eshghi, K. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019
<https://www.scopus.com/pages/publications/85039788312?origin=scopusAI>

78. Step-wise support vector machines for classification of overlapping samples Fu, M., Tian, Y., Wu, F. Neurocomputing, 2015 <https://www.scopus.com/pages/publications/84922897989?origin=scopusAI>

79. Clinical charge profiles prediction for patients diagnosed with chronic diseases using Multi-level Support Vector Machine Zhong, W., Chow, R., He, J. Expert Systems with Applications, 2012
<https://www.scopus.com/pages/publications/81855164880?origin=scopusAI>

80. Categorizing power system stability using clustering based support vector machines Selvi, B.D.A., Kamaraj, N. International Journal of Soft Computing, 2007 <https://www.scopus.com/pages/publications/84884581366?origin=scopusAI>

81. Optimization of Support Vector Machines Based on Sparrow Search Algorithm Zou, R., Xie, H., Zhong, J., Zheng, S. ACM International Conference Proceeding Series, 2023
<https://www.scopus.com/pages/publications/85194869527?origin=scopusAI>

82. Photovoltaic Power Forecasting Using Support Vector Machine and Adaptive Learning Factor Ant Colony Optimization Alabdeli, H., Rafi, S., Naveen, I.G., (...), Nagendar, Y. 3rd IEEE International Conference on Distributed Computing and Electrical Circuits and Electronics, ICDCECE 2024, 2024
<https://www.scopus.com/pages/publications/85196800219?origin=scopusAI>

83. Improving learning from the complex multi-class imbalanced and overlapped data by mapping into higher dimension using SVM++ Mahmood, Z., Jamel, L., Salem, D.A., Ashraf, I. Scientific Reports, 2025
<https://www.scopus.com/pages/publications/105014613924?origin=scopusAI>

84. A novel fusion Support Vector Machine integrating weak and sphere models for classification challenges with massive data Pimentel, J.S., Ospina, R., Ara, A. Decision Analytics Journal, 2024
<https://www.scopus.com/pages/publications/85191005651?origin=scopusAI>
85. Classifying large data sets using SVMs with hierarchical clusters Yu, H., Yang, J., Han, J. Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2003
<https://www.scopus.com/pages/publications/77952390455?origin=scopusAI>
86. Hybrid classification algorithms based on boosting and support vector machines Maia, T.T., Braga, A.P., De Carvalho, A.F. Kybernetes, 2008 <https://www.scopus.com/pages/publications/54949142207?origin=scopusAI>
87. Feature Selection and SVM Parameter Synchronous Optimization Based on a Hybrid Intelligent Optimization Algorithm Wang, Q., Mu, Z. Human-centric Computing and Information Sciences, 2023
<https://www.scopus.com/pages/publications/85168545142?origin=scopusAI>
88. ENHANCING SUPPORT VECTOR MACHINE PERFORMANCE: A HYBRID APPROACH WITH DAVIDON-FLETCHER-POWELL ALGORITHM AND ELEPHANT HERDING OPTIMIZATION (EHO-DFP) FOR PARAMETER OPTIMIZATION Bist, U.S., Singh, N. Transactions of the Royal Institution of Naval Architects Part A: International Journal of Maritime Engineering, 2024
<https://www.scopus.com/pages/publications/85200259555?origin=scopusAI>
89. Complex and hypercomplex-valued Support Vector Machines: A survey Arana-Daniel, N. Applied Sciences (Switzerland), 2019 <https://www.scopus.com/pages/publications/85070718367?origin=scopusAI>
90. Problem formulations and solvers in linear SVM: a review Chauhan, V.K., Dahiya, K., Sharma, A. Artificial Intelligence Review, 2019 <https://www.scopus.com/pages/publications/85040634147?origin=scopusAI>